

分布式图文件系统

What: 什么是分布式图文件系统

Why: 为什么需要分布式图文件系统

How: 如何构建分布式图文件系统



2

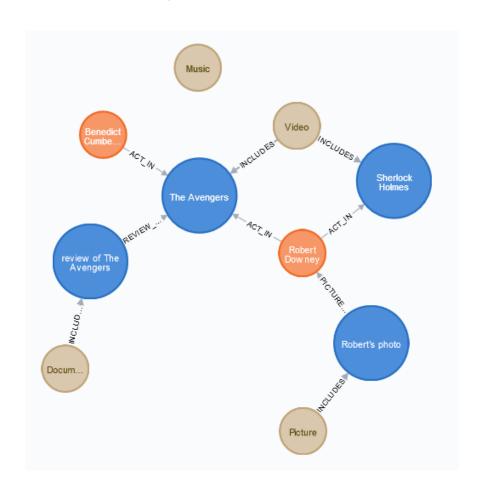


O. WHAT

什么是分布式图文件系统



什么是图文件系统



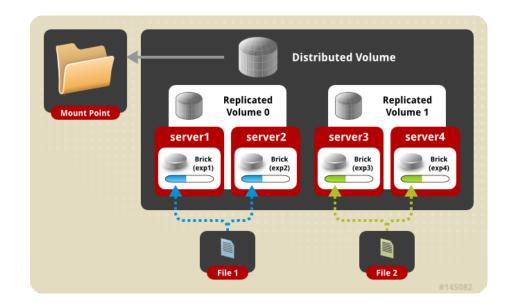
- 逻辑上抛弃树状结构
- 文件之间用"关系"连接
- 基于语义的局部性:有共同特征的 文件相连
- 对存储的需求:基于现有文件系统
- 对计算的需求:对文件语义识别



什么是分布式系统

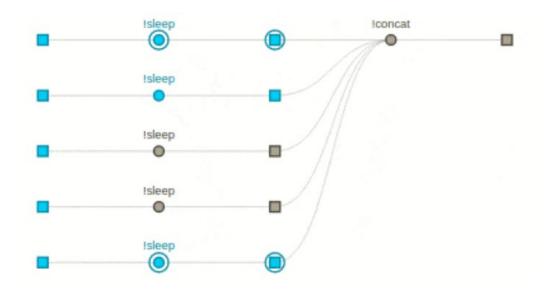
分布式存储

- 块存储、对象存储、分布式文件系统......
- 将单个文件分块存储在不同的机器上
- 充分利用带宽、冗余备份、高安全性、高可用性......



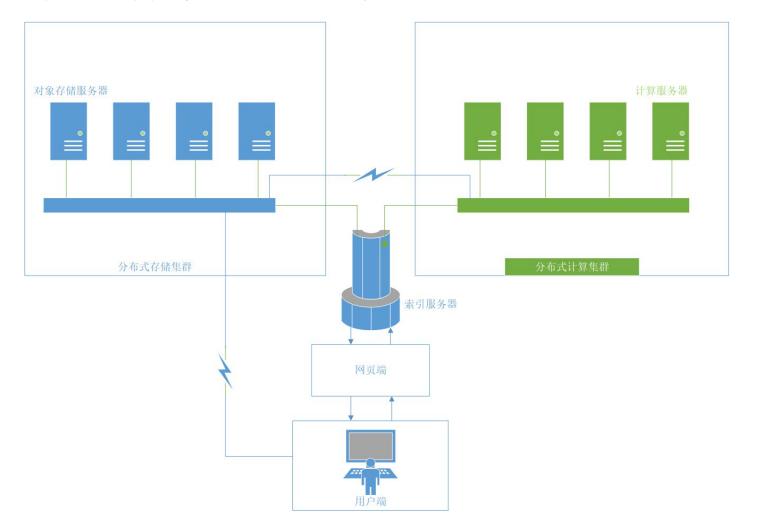
分布式计算

- 将计算任务分配给集群中的不同机器,有序执行
- 可靠性、可扩展性、高性能





什么是分布式图文件系统

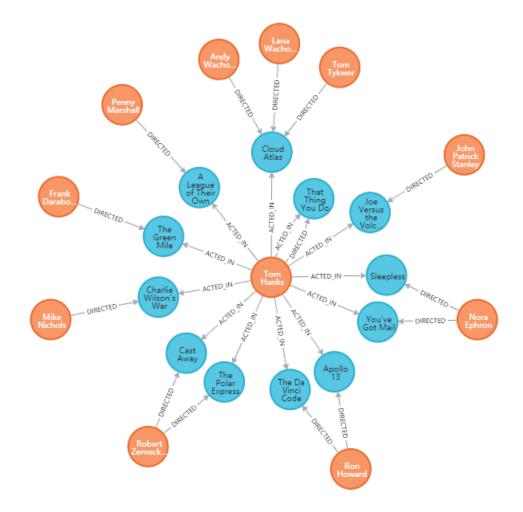


- 底层存储采用分布式存储
- 语义识别采用分布式计算
- 使用图结构描述文件之间的关系

1. WHY

为什么需要分布式图文件系统

图文件系统更贴合人的思维习惯

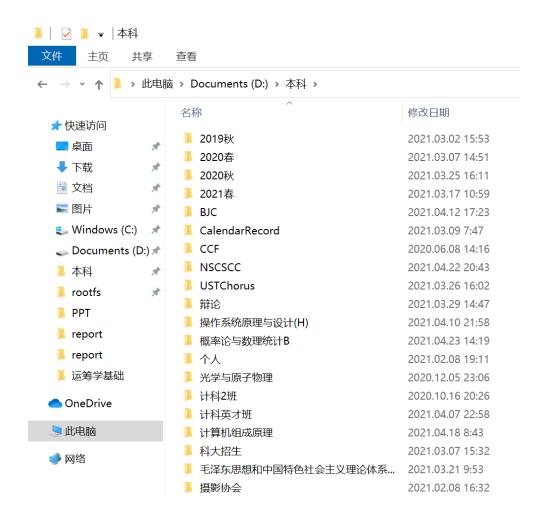




- 树形结构方便机器管理
- 图状结构方便人类用户检索



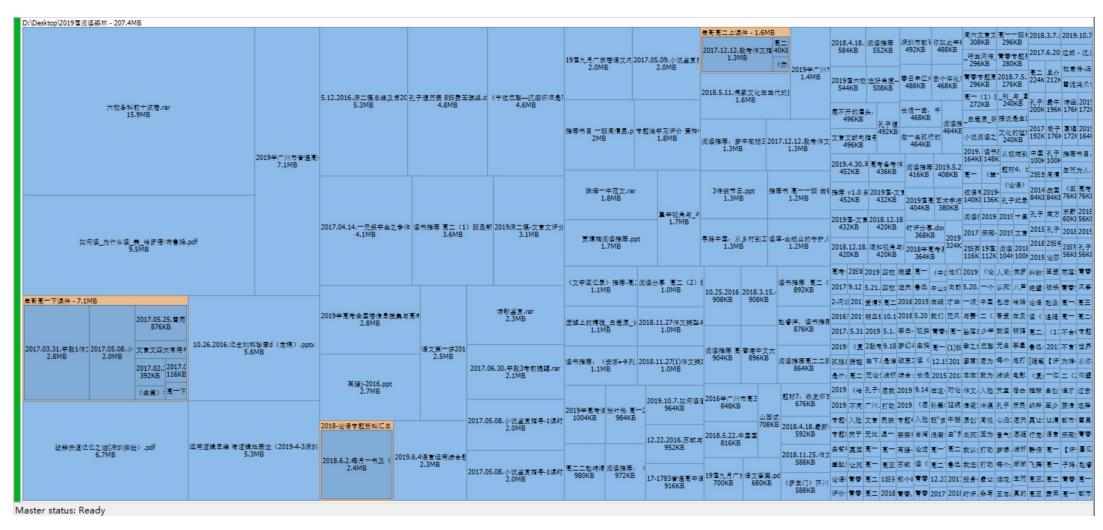
个人使用场景无法充分发挥图文件系统的作用



- 用户会对自己整理的文件有印象
- 人的"印象"本身就是一种图索引



大规模下无法继续依赖"大脑索引"





图文件系统需要走向大规模化、分布化



- 越大的文件系统,越需要语义的局部性
- 分布式存储提供高安全性
- 分布式计算提供高效率

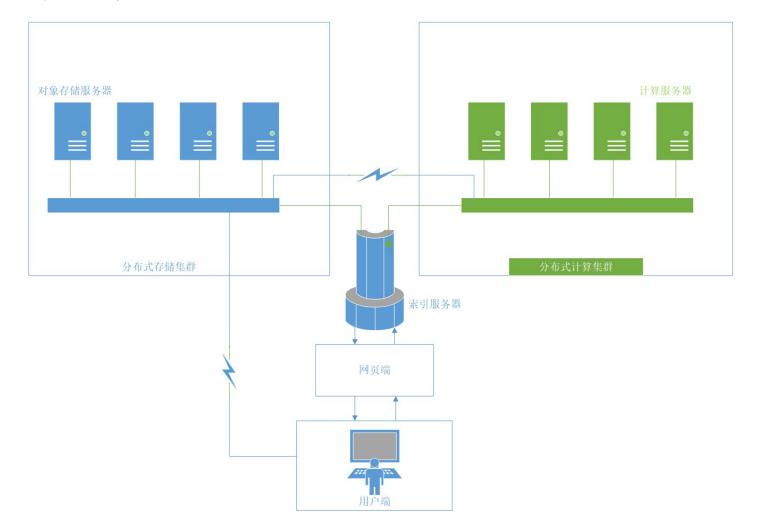


2. HOW

如何构建分布式图文件系统



系统架构



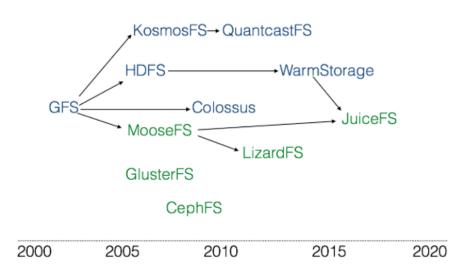
- 申央索引服务器负责调度、维护图数据库、提供用户接口
- 分布式存储集群负责底层存储
- 分布式计算集群负责语义识别任务

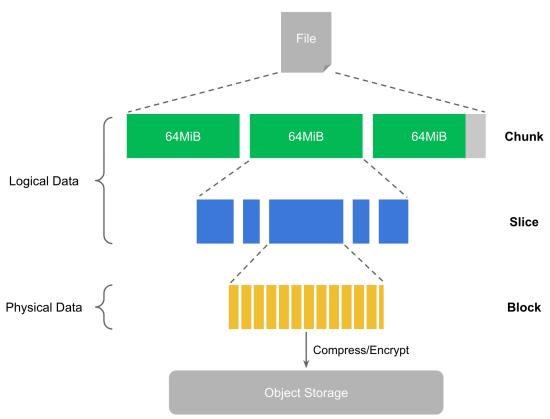


分布式存储集群: JUICEFS+对象存储

- JuiceFS: 2021年开源,基于对象存储的分布式文件系统
- 相当于一个无状态的中间件,帮助各种应用通过标准的文件系 统接口来共享数据

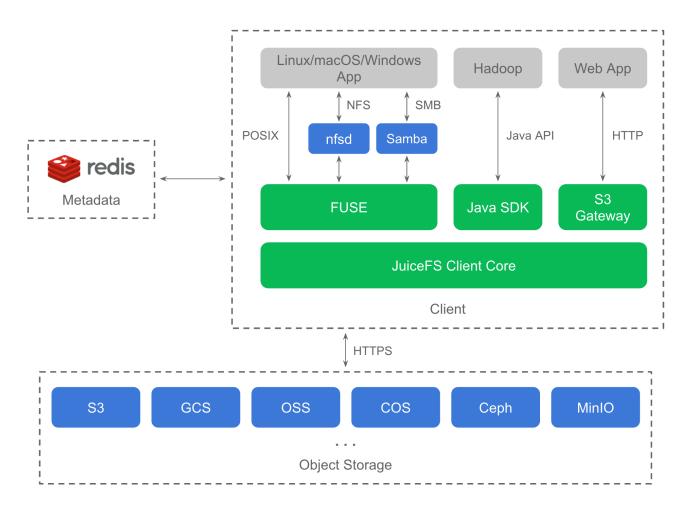
Timeline







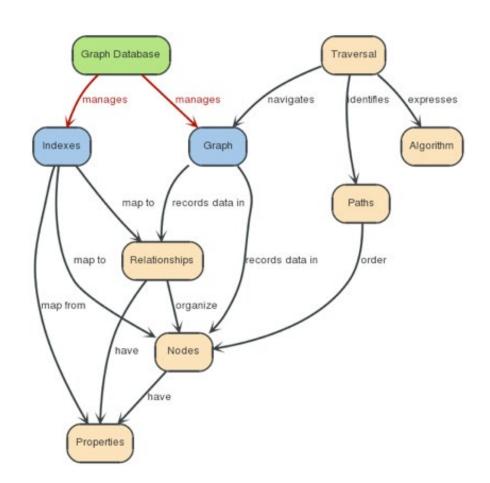
分布式存储集群: JUICEFS+对象存储



- 完整POSIX、S3、Hadoop兼容,服务端、客户端全平台兼容
- 支持阿里云、华为云、Ceph等各种对象存储
- 毫秒级的延迟,近乎无限的吞吐量(取决于 对象存储规模)
- 支持数据加密与数据压缩

Distributes Graph Fite System

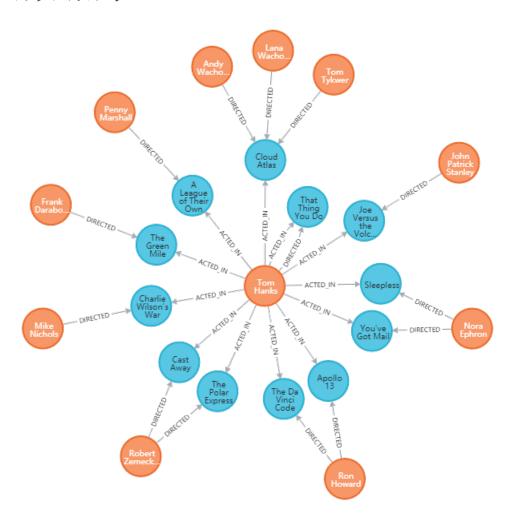
图数据库



- 节点
- 关系
- 属性
- 图操作: 创建、删除、查找、遍历……



图数据库: NEO4J

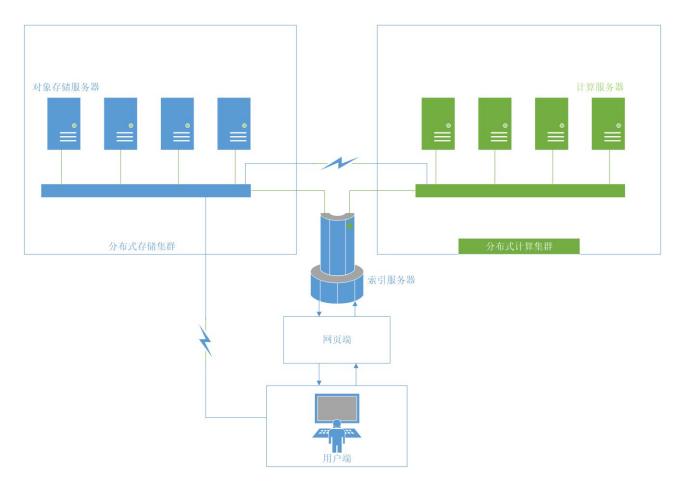


- 极高的市场占有率
- Nosql-图数据库
- Cypher语言
- 强大的可视化工具
- 丰富的API接口

```
match (TomH:Person) where TomH.name='Tom Hanks'
WITH TomH as a
MATCH (a)-[:ACTED_IN]→(m)←[:DIRECTED]-(d) RETURN a,m,d;
```



网页前端



- 尽量减少客户端需求,全平台通用
- 更加用户友好
- 图形化显示图数据库
- 下载文件
- ■删除文件
- 搜索文件
- 上传文件
- 它本身并不做任何实质性的工作,它的作用是将用户的信息发送到对应的服务程序,再由服务程序进行处理。













- 使用neo4j官方提供的d3.js和pototo.js框架
- 结点实时显示
- 使用php与后台服务端进行通信
- 调用服务端提供的应用





文件语义识别



体育	57.26%
海滩	55.48%
滑冰	54.25%
海	48.54%
海洋	45.05%
沙子	41.38%
活动	39.78%
夏季	37.35%
跳跃	35.82%
生活方式	35.47%

LC-3 Assembler Report

Brief Introduction

An LC-3 Assembler implemented with C++. Converts asm file to bin opened with LC-3 Simulator.

Features

- Shows the corresponding lines in . asm file of every 16-bit word.
- Shows the address of every 16-bit word.
- Shows the symbol table.
- Show information of errors if the .asm file is wrongly written.

 The assembler now supports the following kinds of errors:
 - 1. The out-of-range label/offset.
 - 2. The overflowed immediate.
 - 3. Non-existed label.
 - 4. Same-named label indicating multiple addresses.
 - 5. Missing .ORIG/.END

('lc-3 assembler', 0.036)

('arguments', 0.034)

('errors', 0.032)

■ 文本: Python库pke提取关键词

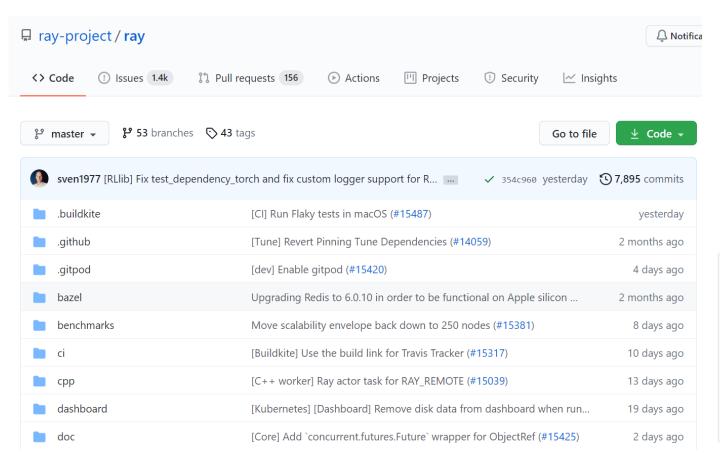
■ 图像:使用imagga提供的tagging接口

语音: speech_recognition: CMUSphinx语音识别 + pke关键词提取

■ 视频:使用tinyTag提取丰富的元数据



分布式计算集群: RAY



- 2017年12月开源
- 高性能分布式计算框架
- 架构完善,社区有强大生命力
- 性能、安全性、可扩展性有保障
- 接口简单易用

```
import ray
ray.init(redis_address="192.168.0.1:6379")

dray.remote
def tagging_task():
    pass #code here

return ray.get(tagging_task.remote())
```

Distributed Graph Fis.System

开发路线

